

# Desarrollo sistema RAG

Autor: Sofía Negueruela Avellaneda

Director: Nicolás Pérez Beltrán

# Metodología de trabajo

Recopilación de datos

Procesamiento e ingesta documental


Investigación sobre grafos de conocimiento

Investigación sobre procesamiento en paralelo


Evaluación y benchmarking



# ¿Qué es un sistema RAG?




# Ingesta documental









# Documentación inconexa



## Graph RAG (Graphiti + Neo4j)



# Procesamiento en paralelo



Encontré 28 perfiles con fra

1. **Guillermo Del Ángel Qui**

Habla alemán (nivel avanzado),  
computer vision, colaboración,  
formación incluye FP en Prog  
un grado en Ciencia e Ingeni

2. **Juan José Montero Luna**

Cuenta con alemán (nivel intermedio),  
Información, organizador de de

3. **Carlos Camps Pujol**

Habla alemán (A2), francés (B2),  
de sistemas y reside en Madrid  
Empresas. (CV: es/cv\_006.json)

4. **Amine Villareal Vila**

Domina alemán (B2, con Goethe),  
Informática, Ciberseguridad y  
Manager. (CV: es/cv\_194.json)

5. **Juan Solano Cardenas**

Pregunta sobre CVs...

Wikipedia English

no speaks french or german?

# Evaluación y resultados

Metodología y casos de uso

## FASE 1 - Generación Gold Standard

Documentos fuente  
(EU, Wikipedia, CVs, ...)

LLM lee *chunks* y genera pares  
{pregunta, respuesta esperada, fuentes}

gold\_standard\_\*.json

Ejemplo de entrada:

```
{
  "id": "eu_es_001",
  "question": "¿Qué reglamento...",
  "expected_answer": "Reglamento (UE)",
  "source_chunks": ["chunk_42"],
  "language": "es",
  "use_case": "eu"
}
```

Revisión humana  
Una sola vez por dataset

## FASE 2 - Ejecución contra el sistema RAG

Itera sobre el *gold standard*  
Envía cada pregunta al sistema RAG

Sistema RAG  
(LangGraph + estrategias)

Por cada pregunta se registra:

Respuesta generada

Nº de llamadas LLM

Tokens (in/out)

Latencia total y por nodo

Chunks recuperados (IDs)

Estrategia y guardrails

Errores / excepciones

Idioma detectado

results\_run.jsonl

```
{
  "question_id": "eu_es_001",
  "answer": "...",
  "retrieved_chunks": [...],
  "llm_calls": 4,
  "tokens_in": 3120,
  "tokens_out": 280,
  "latency_ms": 4180,
  "error": null
}
```

## FASE 3 - Validación con LLM-as-a-Judge

Para cada par  
(expected\_answer, generated\_answer)  
llama a un LLM

Prompt:

"Compara respuesta generada vs esperada.  
Devuelve JSON con:  
- correctness (0-1)  
- completeness (0-1)  
- faithfulness (0-1)  
- similarity (0-1), coincidencia semántica  
- verdict (PASS/FAIL/PARTIAL)  
- explanation"

Métricas adicionales  
(sin LLM):

Similitud coseno  
(embeddings)

Recuperación *chunks*

Tiempo y coste

% preguntas OK

iterar

use\_case.csv

- Tabla por pregunta
- Agregados por use\_case e idioma
- Coste y latencia totales
- Comparativa entre runs

Feedback loop: ajustar prompts, top\_k, estrategia,  
chunking... y volver a ejecutar Fase 2



# CVs

| Idioma | Nº preguntas | OK | KO | Tiempo medio<br>(segundos) | Coste medio<br>(USD) | % OK  |
|--------|--------------|----|----|----------------------------|----------------------|-------|
| EN     | 86           | 64 | 22 | 65,462                     | 0,05374904           | 74.4% |
| ES     | 86           | 37 | 49 | 36,52                      | 0,0050176            | 43.0% |


# Legislación UE

| Idioma | Nº preguntas | OK | KO | Tiempo medio<br>(segundos) | Coste medio<br>(USD) | % OK  |
|--------|--------------|----|----|----------------------------|----------------------|-------|
| ES     | 91           | 47 | 44 | 28,217                     | 0,00566158           | 51.6% |
| EN     | 98           | 60 | 38 | 30,346                     | 0,00630499           | 61.2% |
| FR     | 98           | 54 | 44 | 30,513                     | 0,00668518           | 55.1% |
| IT     | 99           | 56 | 43 | 32,083                     | 0,0068847            | 56.6% |
| PT     | 91           | 54 | 37 | 31,062                     | 0,00649948           | 59.3% |

# Wikipedia

| Idioma | Nº preguntas | OK | KO | Tiempo medio<br>(segundos) | Coste medio<br>(USD) | % OK  |
|--------|--------------|----|----|----------------------------|----------------------|-------|
| ES     | 100          | 78 | 22 | 25,077                     | 0,01010362           | 78.0% |
| EN     | 100          | 82 | 18 | 16,94                      | 0,00932473           | 82.0% |

# Conclusión



# Desarrollo sistema RAG

Autor: Sofía Negueruela Avellaneda

Director: Nicolás Pérez Beltrán