



GRADO EN INGENIERÍA MATEMÁTICA E INTELIGENCIA ARTIFICIAL

ANEXO B

Desarrollo sistema RAG

Autor: Sofía Negueruela Avellaneda

Director: Nicolás Pérez Beltrán

Madrid, Enero 2026

Índice

1	Introducción	1
2	Trabajos Relacionados	2
3	Motivación y Objetivos	3
3.1	Motivación	3
3.2	Objetivos	3
3.3	Alineación con los ODS	4
4	Metodología de trabajo	6
4.1	Cronograma	7
5	Recursos	8
5.1	Software	8
5.2	Hardware	8
5.3	Set de datos	9
6	Bibliografía	10

1 Introducción

En los últimos años, los sistemas de *Retrieval-Augmented Generation* (RAG) han cobrado relevancia debido a su capacidad para combinar modelos de lenguaje con fuentes de conocimiento específicas, proporcionando respuestas más precisas y contextualizadas. No obstante, los enfoques actuales presentan ciertas limitaciones que puede reducir la exhaustividad y fiabilidad de las respuestas generadas.

Este proyecto tiene como objetivo desarrollar una arquitectura RAG modular y escalable que aborde estas limitaciones, integrando técnicas de recuperación avanzada, representación de conocimiento mediante grafos, y modelos de lenguaje abiertos multilingües. La solución propuesta permitirá experimentar con distintas estrategias de recuperación y generación, optimizando la eficiencia computacional y facilitando la evaluación comparativa entre enfoques. De esta manera, se busca contribuir a la creación de sistemas RAG más versátiles, reproducibles y accesibles para la comunidad académica y de investigación.

2 Trabajos Relacionados

En esta sección se revisan los trabajos más relevantes para el proyecto.

- *A systematic review of key retrieval-augmented generation (RAG) systems: Progress, gaps, and future directions.*

Este trabajo presenta un análisis exhaustivo de los sistemas RAG más influyentes, destacando sus características principales, avances recientes y limitaciones persistentes. La revisión de Oche et al. (2025) identifica tendencias emergentes y áreas de mejora, especialmente en lo referente a la integración de fuentes de conocimiento diversas y a la evaluación rigurosa del rendimiento en escenarios reales.

- *Searching for best practices in retrieval-augmented generation.*

Wang et al. (2024) analizan de forma sistemática qué estrategias resultan efectivas en el diseño de sistemas RAG y cuáles tienden a fallar. El estudio identifica patrones comunes, evalúa prácticas consolidadas y documenta errores recurrentes, proporcionando recomendaciones fundamentadas para mejorar la calidad de la recuperación y la generación. Este trabajo constituye una referencia clave para comprender el estado actual de las mejores prácticas en RAG.

- *Efficient retrieval-augmented generation from text and graph via reinforcement learning.*

Este trabajo propone una arquitectura RAG que combina texto y grafos de conocimiento, utilizando técnicas de *reinforcement learning* para optimizar las decisiones de recuperación. El enfoque permite abordar limitaciones de los sistemas tradicionales en escenarios con información distribuida o inconexa, demostrando mejoras en la selección de evidencias relevantes.

A pesar de la investigación completada, sigue habiendo vacíos importantes en este campo: la mayoría de los sistemas RAG existentes no están diseñados para operar de forma nativa en múltiples idiomas, presentan dificultades en escenarios con documentación inconexa y rara vez ofrecen arquitecturas modulares que permitan comparar estrategias de recuperación de manera sistemática. Estas limitaciones justifican el desarrollo de la arquitectura propuesta en este trabajo.

3 Motivación y Objetivos

3.1 Motivación

Los sistemas RAG actuales suelen apoyarse en arquitecturas de recuperación vectorial que, si bien resultan eficaces para consultas generales, presentan dificultades en ciertos contextos como consultas complejas de tipo enumerativo (por ejemplo: “dame una lista con todos los elementos que cumplan...”), donde la recuperación de un subconjunto limitado de documentos puede derivar en respuestas incompletas.

Con el fin de abordar estas limitaciones, se realizará un estudio comparativo de arquitecturas RAG existentes, abarcando tanto enfoques tradicionales basados exclusivamente en recuperación vectorial como propuestas más recientes que integran recuperación basada en metadatos, flujos de búsqueda múltiples o estructuras de conocimiento en forma de grafos, analizando sus ventajas y limitaciones en contextos multilingües. A partir de este análisis, se diseñará una arquitectura RAG modular y escalable, con soporte multiidioma nativo, que permita incorporar e intercambiar distintos mecanismos de recuperación de información de manera flexible y extensible.

Además, se implementarán varios casos de uso reales, que permitirán evaluar el comportamiento del sistema en situaciones prácticas y representativas. Estos casos de uso servirán no solo para validar la arquitectura propuesta, sino también para documentar de forma sistemática las conclusiones del análisis, identificando fortalezas, limitaciones y oportunidades de mejora de los distintos enfoques explorados.

3.2 Objetivos

El objetivo principal del trabajo es desarrollar un sistema RAG modular y escalable que soporte múltiples idiomas utilizando modelos y herramientas open source, eliminando la dependencia de servicios propietarios como OpenAI. Se busca que la solución resultante sirva como base para futuras extensiones y experimentos, facilitando la comparación rigurosa entre diferentes estrategias de recuperación y generación.

- **Procesamiento Multiidioma de Documentos**

- Detección automática de idioma de documentos
- Adaptación del *chunking* según características lingüísticas de cada idioma
- Procesamiento específico para diferentes tipos de documento (PDF, Word, etc.)

- **Sistema de Embeddings Open Source**

- Integración de modelos de embeddings multiidioma (ej.: *multilingual-e5*, SBERT multilingual) y comparativas entre estos modelos
- Optimización del índice vectorial (con alternativas como Qdrant, Weaviate)

- **Recuperación Avanzada y Representación del Conocimiento**

- Análisis de las limitaciones de la recuperación vectorial clásica
- Exploración de técnicas de recuperación enriquecida mediante metadatos estructurados y grafos de conocimiento
- Representación de entidades y relaciones extraídas durante la ingesta documental para mejorar la exhaustividad de las respuestas

- **Sistema de Keywords y Metadatos**

- Extracción de *keywords* específica por idioma
- Adaptación de los metadatos del índice para soportar múltiples idiomas

- **Generación con LLMs Open Source**

- Integración de modelos como Llama 3, Mistral o Phi-3
- Implementación de técnicas de optimización (quantización, LoRA)
- Sistema de *prompting* multiidioma

- **Evaluación y Benchmarking**

- Métricas de calidad de respuestas (relevancia, precisión, completitud)
- Análisis de costes y recursos computacionales
- Evaluación específica por idioma (español, inglés, francés, etc.)

- **Estrategias Experimentales de Recuperación y Generación**

- Exploración de flujos de recuperación alternativos, incluyendo búsquedas iterativas o paralelas
- Análisis de enfoques basados en múltiples consultas o agentes ligeros para mejorar la cobertura de la información recuperada
- Comparación experimental entre estrategias de recuperación única y estrategias avanzadas en escenarios con documentos inconexos

3.3 Alineación con los ODS

El proyecto contribuye a varios Objetivos de Desarrollo Sostenible (ODS) de la ONU:

- **ODS 4 – Educación de calidad:** “Garantizar una educación inclusiva y equitativa de calidad y promover oportunidades de aprendizaje permanente para todos”. La puesta a disposición de una arquitectura RAG *open source* y su documentación facilitan el acceso al conocimiento, la reproducción de experimentos y el uso educativo en contextos universitarios y de formación profesional, promoviendo la capacitación en técnicas modernas de procesamiento del lenguaje y recuperación de información.

- **ODS 9 – Industria, innovación e infraestructura:** “Construir infraestructuras resilientes, promover la industrialización inclusiva y fomentar la innovación”. El desarrollo de una infraestructura modular y reproducible de sistemas RAG favorece la innovación tecnológica, la transferencia de conocimiento y la adopción de soluciones escalables que pueden integrarse en procesos industriales y plataformas de investigación.
- **ODS 16 – Paz, justicia e instituciones sólidas:** “Crear instituciones eficaces, responsables y transparentes”. Al reducir la dependencia de servicios propietarios y fomentar la transparencia y trazabilidad en los sistemas de recuperación y generación de información, el proyecto contribuye a la gobernanza tecnológica responsable y a la confianza en herramientas basadas en inteligencia artificial.

4 Metodología de trabajo

El proyecto se organiza en una serie de tareas que permiten cumplir los objetivos propuestos

- **Revisión bibliográfica y recopilación de datos**

- Revisión de trabajos previos sobre RAG, embeddings multilingües y grafos de conocimiento
- Selección de datasets y colecciones de documentos en múltiples idiomas

PRÁCTICA



- **Procesamiento e ingesta documental**

- Detección automática de idioma y normalización de documentos
- *Chunking* y extracción de metadatos y keywords por idioma
- Preparación de fragmentos para indexación
- Creación de índices + indexación de los



- **Embeddings e indexación vectorial**

TEORÍA (analizar e investigar solo a nivel teórico, y explicar lo que usamos)

- Integración y comparativa de modelos de embeddings multilingües
- Optimización de índices y  (Qdrant, Weaviate)

ada, etc...
Teoría

ada es el modelo de embedding de openai

- **Recuperación avanzada y grafos de conocimiento**

- Implementación de estrategias de recuperación avanzadas (múltiples consultas, búsquedas iterativas/paralelas)
- Construcción de grafos de conocimiento a partir de entidades y relaciones extraídas
- Integración de mecanismos de fusión de evidencias para consultas complejas

- **Integración de LLMs y generación multiidioma**

- Integración de modelos open source (Llama 3, Mistral, Phi-3) y aplicación de técnicas de optimización (LoRA, quantización)
- Diseño de prompts y plantillas multiidioma

Estudio teórico de

Esto será solo a nivel teórico, la gracia está en "investigar" sobre prompt engineering y contar un poco cómo he ido construyendo los prompts y todo eso

- **Evaluación y benchmarking**

- Ejecución de experimentos con métricas por idioma y tipo de consulta
- Análisis de costes y recursos computacionales
- Documentación de resultados y entrega de materiales reproducibles

Cada fase está planificada en el cronograma de la siguiente sección, permitiendo un seguimiento claro y medible del avance del proyecto.

4.1 Cronograma

El cronograma presentado distribuye las tareas planificadas a lo largo del período de ejecución del proyecto, permitiendo un seguimiento ordenado y sistemático de los avances. Además de las actividades descritas en la metodología, se ha incluido la tarea específica de redacción del TFG, asegurando que el proceso de documentación se integre de manera coherente con el desarrollo técnico del proyecto.

Las tareas se han organizado por semanas, lo que facilita el control de tiempos y el seguimiento del progreso de manera más detallada. Cabe destacar que este cronograma tiene carácter orientativo y no es estrictamente vinculante; su propósito principal es servir como guía de planificación, pudiendo adaptarse a cambios o ajustes según las necesidades que surjan durante la ejecución del trabajo.

	Ene		Feb				Mar				Abr					May			
	S3	S4	S1	S2	S3	S4	S1	S2	S3	S4	S1	S2	S3	S4	S5	S1	S2	S3	S4
1 Revisión bibliográfica y recopilación de datos																			
2 Procesamiento e ingesta documental																			
3 Embeddings e indexación vectorial																			
4 Recuperación avanzada y grafos de conocimiento																			
5 Integración de LLMs y generación multiidioma																			
6 Evaluación y benchmarking																			
7 Redacción y entrega del TFG																			

5 Recursos

5.1 Software

Para el desarrollo del proyecto se utilizarán herramientas y librerías software ampliamente reconocidas en los ámbitos de procesamiento de lenguaje natural, recuperación de información y *machine learning*, garantizando compatibilidad con los objetivos propuestos. No obstante, la selección final dependerá de los resultados obtenidos durante el proceso. Este listado refleja únicamente las tecnologías que se prevé utilizar de forma preliminar, antes de llevar a cabo una investigación exhaustiva que determine las librerías empleadas en el proyecto.

- **Lenguajes de programación:** Python (versión 3.10 o superior), por su amplio ecosistema de librerías especializadas en NLP y aprendizaje automático.
- **Librerías y frameworks para NLP y embeddings:**
 - Hugging Face Transformers, Llama y Qwen para la integración y uso de modelos de lenguaje preentrenados (LLMs) y modelos de embeddings multilingües.
 - Sentence-Transformers y KaLM para generación de embeddings de alta calidad y comparativas entre diferentes modelos multilingües.
- **Motores de búsqueda vectorial:**
 - Qdrant y Weaviate como alternativas de bases de datos vectoriales para indexación y recuperación eficiente de documentos.
- **Herramientas de gestión de grafos de conocimiento:**
 - NetworkX para construcción, análisis y visualización de grafos de entidades y relaciones extraídas.

Todo el software seleccionado es open source o cuenta con versiones gratuitas adecuadas para desarrollo académico, facilitando la reproducibilidad y el acceso a los materiales por parte de la comunidad investigadora.

5.2 Hardware

Para el desarrollo del proyecto se emplearán recursos computacionales en tres niveles:

- **Ordenador personal:** Se utilizará para desarrollo, pruebas iniciales y procesamiento de datos. Las tareas como preprocesamiento de documentos, generación de embeddings ligeros y desarrollo de prototipos se podrán realizar en CPU (intel 5) idealmente.

- **Segundo ordenador personal:** Se dispone de un ordenador adicional con mayor capacidad de CPU (Ryzen 7), que podrá utilizarse para tareas más intensivas en procesamiento que aún no requieran GPU, como pruebas más rápidas de embeddings o análisis de datos a mayor escala.
- **Equipos del Laboratorio de IA:** Para entrenamiento y pruebas de modelos grandes, generación de embeddings a gran escala o experimentos que requieran aceleración por GPU, se accederá a los ordenadores del laboratorio de Inteligencia Artificial de la universidad (ICAI). Estos equipos disponen de GPU y memoria suficiente para ejecutar modelos y procesos que no podrían realizarse eficientemente en un ordenador personal.

Esta configuración permite combinar flexibilidad y eficiencia, desarrollando la mayor parte del proyecto en los ordenadores personales y recurriendo al laboratorio únicamente cuando sea necesario, optimizando así el tiempo y los recursos disponibles.

5.3 Set de datos

El proyecto utilizará conjuntos de datos de texto en múltiples idiomas para evaluar y comparar diferentes estrategias de recuperación y generación de información. Estos datos podrán provenir de fuentes públicas disponibles, como artículos, documentos académicos o colecciones de texto en distintos idiomas, siempre asegurando la legalidad y la disponibilidad para uso académico.

Además, existe la posibilidad de generar datos artificiales con inteligencia artificial para complementar los conjuntos disponibles o crear casos de prueba específicos. Estos datos sintéticos permitirán simular situaciones concretas y asegurar la diversidad y exhaustividad de las evaluaciones, garantizando que la arquitectura RAG desarrollada pueda ser probada de manera flexible y controlada.

6 Bibliografía

Oche et al., 2025 Wang et al., 2024 Guo et al., 2025

Guo, Y., Su, M., Guan, S., Sun, Z., Jin, X., Guo, J., & Cheng, X. (2025). Routerag: Efficient retrieval-augmented generation from text and graph via reinforcement learning. *arXiv*. <https://arxiv.org/abs/2512.09487>

Oche, A. J., Folashade, A. G., Ghosal, T., & Biswas, A. (2025). A systematic review of key retrieval-augmented generation (rag) systems: Progress, gaps, and future directions. *arXiv*. <https://arxiv.org/abs/2507.18910>

Wang, X., Wang, Z., Gao, X., Zhang, F., Wu, Y., Xu, Z., Shi, T., Wang, Z., Li, S., Qian, Q., Yin, R., Lv, C., Zheng, X., & Huang, X.-J. (2024). Searching for best practices in retrieval-augmented generation. *ACL Anthology, EMNLP 2024*. <https://aclanthology.org/2024.emnlp-main.981/>